



UNIVERSIDADE PRESBITERIANA MACKENZIE

Tecnologia em Banco de Dados

Kayo Oliveira Nukui (TIA 10356420)

PROJETO APLICADO III

Recomendação de filmes por similaridade de conteúdo em um catálogo IMDb

Osasco/SP, 2026

SUMÁRIO

1 INTRODUÇÃO	3
2 REFERENCIAL TEÓRICO	4
2.1 Sistemas de recomendação baseados em conteúdo	4
2.2 Representação TF-IDF e similaridade do cosseno	4
2.3 Linhas de base e avaliação offline	5
2.4 Trabalhos relacionados	5
REFERÊNCIAS	5

1 INTRODUÇÃO

Ao procurar um filme parecido com outro de que gostou, uma pessoa precisa comparar muitas opções de um catálogo. Este projeto propõe ordenar filmes pela semelhança entre suas descrições. O público considerado é quem quer descobrir títulos próximos de um filme conhecido.

A base escolhida não registra avaliações de cada pessoa. Por isso, o ponto de partida é comparar o conteúdo dos filmes, sem criar perfis individuais. A semelhança entre enredos já foi estudada como recurso para recomendar filmes quando há informação textual sobre os títulos (ILIPOULOU et al., 2020). Uma sinopse parecida, porém, não garante que a recomendação agrade ao público. A utilidade das sugestões terá de ser avaliada separadamente.

O objetivo geral é desenvolver e avaliar uma prova de conceito reproduzível de recomendação de filmes por conteúdo. Para isso, o projeto deverá verificar a base, preparar as sinopses, calcular a semelhança entre títulos, produzir listas de recomendação e examinar seus resultados com critérios explícitos.

A fonte é o conjunto “IMDB Dataset of Top 1000 Movies and TV Shows”, publicado no Kaggle por Harshit Shankhdhar ([s. d.]) e obtido em setembro de 2026. O arquivo tem 1.000 registros e 16 colunas, entre elas título, sinopse, gêneros, diretor, elenco principal, ano, duração, classificação indicativa, notas, número de votos e bilheteria. Não há identificação de usuários nem histórico de interações, o que impede uma recomendação personalizada baseada nesse histórico. No Kaggle, a base é apresentada com licença CC0 1.0.

A análise exploratória encontrou 1.000 registros, sem linhas inteiramente duplicadas, e 999 títulos distintos: duas versões de Drishyam têm o mesmo nome, mas são filmes diferentes. Há valores ausentes em Certificate (101 registros), Meta_score (157) e Gross (169). Também foi encontrado o texto PG no campo de ano de Apollo 13, que deveria conter um número. Entre os 21 gêneros identificados, Drama aparece em 724 filmes (72,4%). Como o catálogo reúne títulos bem avaliados, com nota mínima de 7,6, ele não representa todos os filmes disponíveis ao público.

As sinopses têm mediana de 24 palavras, o que oferece pouco texto para comparar os filmes. A frequência de Drama também exige cautela: compartilhar esse gênero não basta para concluir que uma sugestão seja relevante. Na preparação, os 1.000 registros foram mantidos; campos vazios continuaram ausentes, e o ano inválido de Apollo 13 foi tratado como ausente, sem inventar um valor. O arquivo preparado passou de 16 para 18 colunas, com identificador para distinguir títulos iguais e campos derivados para apoiar a análise. O notebook 02 registra

a exploração e a preparação; o notebook 03 apresenta a prova de conceito e a avaliação preliminar. Ambos, com os arquivos de apoio, estão disponíveis no repositório do projeto: <https://github.com/nukui96/mackenzie-pa3-imdb-movies-review>.

Como objetivo extensionista, propõe-se usar as recomendações em uma atividade de escolha e conversa sobre filmes com um grupo de estudos ou cineclube. A proposta pode dialogar com o ODS 4 (Educação de Qualidade), desde que o público e o vínculo educacional sejam definidos. Até esta etapa, não houve aplicação na comunidade.

2 REFERENCIAL TEÓRICO

2.1 Sistemas de recomendação baseados em conteúdo

Um recomendador baseado em conteúdo compara as características dos itens com os interesses de uma pessoa (LOPS; GEMMIS; SEMERARO, 2011). Como esta base não contém histórico de usuários, o projeto compara um filme escolhido com os demais títulos. O resultado é uma lista de filmes semelhantes ao filme consultado, e não uma recomendação personalizada.

2.2 Representação TF-IDF e similaridade do cosseno

No modelo de espaço vetorial, cada texto se torna um conjunto de pesos numéricos para seus termos (MANNING; RAGHAVAN; SCHÜTZE, 2008). O TF-IDF combina a frequência de um termo no texto com sua raridade no conjunto de textos: palavras presentes em muitos filmes recebem menos peso. Sparck Jones (1972) discutiu a especificidade dos termos; Salton e Buckley (1988) compararam formas de ponderá-los. Na expressão básica abaixo, N é o número de textos e $df(t)$ é o número de textos que contêm o termo t :

$$w(t, d) = tf(t, d) \times \log [N / df(t)] \quad (1)$$

A similaridade do cosseno entre dois vetores a e b é o produto interno dividido pelo produto de suas normas euclidianas $|a|$ e $|b|$:

$$\cos(a, b) = (a \cdot b) / (|a| \times |b|) \quad (2)$$

Com pesos não negativos, o cosseno varia de 0 a 1; vale zero quando os textos não compartilham termos (MANNING; RAGHAVAN; SCHÜTZE, 2008). O scikit-learn usa IDF suavizado e normaliza os vetores, portanto os cálculos deste projeto seguem a biblioteca, não literalmente a Equação 1 (PEDREGOSA et al., 2011). O método não reconhece por si só sinônimos ou frases de sentido parecido escritas com palavras diferentes. Esse limite importa porque as sinopses do catálogo são curtas.

2.3 Linhas de base e avaliação offline

Uma avaliação offline compara as listas do recomendador com um critério definido antes do teste, sem consultar pessoas naquele momento. Cremonesi, Koren e Turrin (2010) estudam a avaliação de listas Top-N. Neste projeto, as listas por popularidade e por sorteio foram escolhidas como comparações simples. Essa escolha é nossa, não uma exigência desses autores.

Como a base não contém julgamentos de relevância, a prova de conceito usa um indicador indireto: verificar se o filme recomendado compartilha ao menos um gênero com o filme consultado. Isso mede coincidência de categorias, não preferência de uma pessoa. O indicador pode parecer alto só porque um gênero é frequente no catálogo; por isso, também é comparado com a taxa esperada de um sorteio.

2.4 Trabalhos relacionados

Iliopoulou et al. (2020) estudaram a semelhança entre enredos de filmes com TF-IDF e outras técnicas, usando também dados de avaliações. Permana e Wibowo (2023) combinaram termos de sinopses, gêneros, TF-IDF e similaridade do cosseno em outra base; os autores relatam limites na relevância das sugestões. Esses trabalhos sustentam o uso de descrições textuais, mas suas métricas não podem ser transferidas para este catálogo, que não contém avaliações individuais.

REFERÊNCIAS

CREMONESI, Paolo; KOREN, Yehuda; TURRIN, Roberto. Performance of recommender algorithms on top-N recommendation tasks. In: **Proceedings of the fourth ACM conference on Recommender systems**. [S. l.]: ACM, 2010. p. 39-46. DOI: 10.1145/1864708.1864721.

ILIOPOULOU, Konstantina et al. Improving movie recommendation systems filtering by exploiting user-based reviews and movie synopses. **Artificial Intelligence Applications and Innovations**. [S. l.]: Springer, 2020. v. 585, p. 187-199. DOI: 10.1007/978-3-030-49190-1_17.

LOPS, Pasquale; GEMMIS, Marco de; SEMERARO, Giovanni. Content-based recommender systems: state of the art and trends. In: **Recommender systems handbook**. [S. l.]: Springer US, 2011. p. 73-105. DOI: 10.1007/978-0-387-85820-3_3.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. **Introduction to information retrieval**. Cambridge: Cambridge University Press, 2008. Disponível em: <https://nlp.stanford.edu/IR-book/>. Acesso em: 2 out. 2026.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [s. l.], v. 12, p. 2825-2830, 2011. Disponível em: <https://www.jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 2 out. 2026.

PERMANA, Armadhani Hiro Juni; WIBOWO, Agung Toto. Movie recommendation system based on synopsis using content-based filtering with TF-IDF and cosine similarity.

International Journal on Information and Communication Technology, [s. l.], v. 9, n. 2, p. 1-14, 2023. DOI: 10.21108/ijoiict.v9i2.747.

SALTON, Gerard; BUCKLEY, Christopher. Term-weighting approaches in automatic text retrieval. **Information Processing & Management**, [s. l.], v. 24, n. 5, p. 513-523, 1988. DOI: 10.1016/0306-4573(88)90021-0.

SHANKHDHAR, Harshit. **IMDB Dataset of Top 1000 Movies and TV Shows**: top 1000 movies by IMDB rating. [S. l.]: Kaggle, [s. d.]. Disponível em: <https://www.kaggle.com/datasets/harshitshankhdhar/imdb-dataset-of-top-1000-movies-and-tv-shows>. Acesso em: 29 set. 2026.

SPARCK JONES, Karen. A statistical interpretation of term specificity and its application in retrieval. **Journal of Documentation**, [s. l.], v. 28, n. 1, p. 11-21, 1972. DOI: 10.1108/eb026526.